


Prédiction du Défaut de Paiement pour les cartes de crédit : Étude Comparative de 4 Modèles de Machine Learning

Gurvann BRILLET, Yamba Arsène GOUBGOU

ENSAE Paris — Applied Statistical Learning — Prof. DALALYAN Arnak

13 Janvier 2026



INSTITUT
POLYTECHNIQUE
DE PARIS

Plan

Motivation

Données

Analyse descriptive

Modèles

Conclusion

Motivation et objectif

- ▶ Le défaut de paiement constitue un enjeu central pour la stabilité financière et la rentabilité des banques.
- ▶ Les décisions de crédit reposent sur l'anticipation du risque de défaut.
- ▶ Objectif : Comparer des modèles prédictifs du défaut de paiement à partir de données clients.
- ▶ Problème clé : classes fortement déséquilibrées $\Rightarrow$ priorité au **rappel** sur la classe défaut dans notre analyse.

Présentation des données

- ▶ Jeu de données réel : 30 000 clients d'une banque taïwanaise.
- ▶ Informations observées entre avril et septembre 2005.
- ▶ Variable cible : défaut de paiement en octobre 2005.
- ▶ 22,1% des clients sont en situation de défaut.
- ▶ 23 variables explicatives réparties en trois catégories :
 - ▶ **Financières** : limite de crédit, factures mensuelles, remboursements.
 - ▶ **Socio-démographiques** : âge, sexe, niveau d'éducation, situation matrimoniale.
 - ▶ **Comportementales** : historique des retards de paiement.

Analyse descriptive : Tableau résumé



Table: Statistiques descriptives des principales variables numériques

Variable	Moyenne	Écart-type	Min	Médiane	Q3	Max
Limite de crédit (kNT\$)	167.5	129.7	10	140	240	1000
Âge (années)	35.5	9.2	21	34	41	79
Factures Sept. (kNT\$)	51.2	73.6	-165.6	22.4	67.1	964.5
Factures Août (kNT\$)	49.2	71.2	-69.8	21.2	64.0	983.9
Factures Juil. (kNT\$)	47.0	69.3	-157.3	20.1	60.2	1664.1
Versements Sept. (kNT\$)	5.7	16.6	0	2.1	5.0	873.6
Versements Août (kNT\$)	5.9	23.0	0	2.0	5.0	1684.3
Versements Juil. (kNT\$)	5.2	17.6	0	1.8	4.5	896.0

Analyse descriptive: Commentaire


- ▶ **Forte hétérogénéité des capacités de financement :**
 - ▶ limite de crédit moyenne de **167 kNT\$** pour une médiane de **140 kNT\$**,
 - ▶ dispersion élevée (écart-type **130 kNT\$**), avec un maximum à **1 MNT\$**.
- ▶ **Structure démographique jeune :**
 - ▶ âge moyen de **35,5 ans**, médiane **34 ans**,
 - ▶ 75% des clients ont moins de **41 ans**.
- ▶ **Montants facturés très asymétriques :**
 - ▶ médianes mensuelles autour de **17–22 kNT\$**,
 - ▶ présence de soldes créditeurs (minima négatifs) et de valeurs extrêmes élevées.
- ▶ **Comportement de remboursement contrasté :**
 - ▶ remboursements médians faibles (**1,5–2 kNT\$**),
 - ▶ distributions très étalées (jusqu'à **1,6 MNT\$**).

Distributions selon le statut de défaut



- ▶ Les clients en défaut présentent des limites de crédit plus faibles.
- ▶ Les remboursements sont plus fortement concentrés autour de 0 NT\$ à fortiori à l'approche d'octobre.
- ▶ Le comportement de paiement apparaît comme un discriminant majeur.


Corrélations entre les montants facturés et effet de stock



- Forte corrélation entre les montants facturés sur différents mois.
- Présence d'un effet de stock dans l'endettement.
- Risque de multicolinéarité pour les modèles linéaires.


Comparaison globale des performances des modèles

Figure: Matrices de Confusion sur les Données de Test des 4 modèles implémentés






- Performances globales proches en accuracy.
- Différences marquées sur le rappel de la classe défaut.
- Les modèles non-linéaires surpassent la régression logistique.



Forêt aléatoire et XGBoost



Forêt Aléatoire



XGBoost



- Amélioration nette du rappel par rapport au modèle linéaire.
- Bonne gestion des non-linéarités et des interactions.


Comparaison globale des performances

Table: Comparaison des modèles de prédiction (triée par rappel)

Modèle	Accuracy	Rappel (Classe Défaut)	Précision (Classe Défaut)
Forêt Aléatoire	0.813	0.365	0.632
XGBoost	0.817	0.359	0.660
Réseau de Neurones	0.794	0.344	0.555
Régression Logistique	0.809	0.244	0.692

- ▶ **Arbitrage Performance** : La Forêt Aléatoire présente le meilleur rappel, critère crucial pour identifier les profils à risque.
- ▶ **Modèles de Boosting** : Ils surpassent nettement l'approche linéaire en capture du risque (rappel).
- ▶ **Observation** : L'Accuracy reste stable entre les modèles, soulignant l'importance de regarder les métriques par classe.

Importance des variables – Forêt aléatoire



- ▶ Le statut de paiement le plus récent est le facteur dominant.
- ▶ Les variables financières récentes expliquent l'essentiel du risque.
- ▶ Les variables socio-démographiques (hors âge) ont un poids marginal.

Conclusion et Perspectives

Conclusion

- ▶ Construction de modèles de prédiction à partir de données réelles.
- ▶ Le **Random Forest** performe mieux en rappel, proche du XG-Boost.
- ▶ Importance centrale du **comportement de paiement**.
- ▶ Limite : fort déséquilibre entre les classes.

Perspectives

- ▶ Ajustement du seuil de décision pour optimiser le rappel.
- ▶ Intégration d'une fonction de coût bancaire (coût d'un faux négatif).