

Applied Statistical Learning

Rapport de Projet d'Application

Prédiction du Défaut de Paiement pour les cartes de crédit : Étude Comparative de 4 Modèles de Machine Learning

BRILLET Gurvann, GOUBGOU Yamba Arsène



ENSAE PARIS - IP

Prof. DALALYAN Arnak

9 janvier 2026

1 Introduction

Ce projet vise à analyser et modéliser le risque de défaut de paiement sur les cartes de crédit, un enjeu majeur pour la stabilité financière et la rentabilité des banques. L'étude s'appuie sur un échantillon de 30 000 clients d'une banque taïwanaise (données d'octobre 2005) et cherche à transformer des données historiques en outils prédictifs permettant d'anticiper les impayés. Dans ce jeu de données, 22,12 % des clients (soit 5 529 individus) sont en situation de défaut, définie par un retard de paiement inférieur au seuil minimal requis par leur contrat.

2 Analyse détaillée de la base de données

Cette première partie vise à analyser en détail la base de données. Il s'agit notamment d'étudier les modalités des variables explicatives et leur distribution en relation avec le défaut de paiement. Le jeu de données comporte 23 potentiels prédicteurs détaillés dans la Table 1 ci-dessous.

Table 1: Description des variables explicatives - Base de données UCI Credit Card

Variable	Description	Détails / Codage
limit_bal	Montant du Crédit Accordé par le contrat	Montant total de la limite en dollars taïwanais (NT\$)
sex	Genre	1 = Homme ; 2 = Femme
education	Éducation	1 = Études supérieures ; 2 = Université ; 3 = Lycée ; 4 = Autre
marriage	État civil	1 = Marié ; 2 = Célibataire ; 3 = Autre
age	Âge	Âge en années
payment_status_sep – payment_status_apr	Historique des paiements	État du remboursement (sept. à avril 2005) -2 = Inactif; 0 = Crédit Renouvelable; -1 = À jour ; 1 = Retard d'un mois ; 2 = Deux mois...
bill_statement_sep – bill_statement_apr	Montant des factures	Solde du relevé mensuel (sept. à avril 2005) en NT\$
previous_payment_sep – previous_payment_apr	Montants versés	Somme payée lors du dernier relevé (sept. à avril) en NT\$

La Table 2 Ci-dessous détaille les statistiques descriptives des variables numériques de la base (toutes les variables à l'exception de l'éducation, de l'état civil et du sexe).

Table 2: Statistiques descriptives (Valeurs en milliers de NT\$ - kNT\$)

Variable	Moyenne	Écart-type	Min	Médiane	75%	Max
Limite de Crédit (kNT\$)	167,5	129,7	10	140	240	1000
Âge (Années)	35,5	9,2	21	34	41	79
Factures (kNT\$)						
Septembre	51,2	73,6	-165,6	22,4	67,1	964,5
Août	49,2	71,2	-69,8	21,2	64	983,9
Juillet	47	69,3	-157,3	20,1	60,2	1 664,1
Juin	43,3	64,3	-170	19,1	54,5	891,6
Mai	40,3	60,8	-81,3	18,1	50,2	927,2
Avril	38,9	59,6	-339,6	17,1	49,2	961,7
Versements (kNT\$)						
Septembre	5,7	16,6	0	2,1	5	873,6
Août	5,9	23	0	2	5	1 684,3
Juillet	5,2	17,6	0	1,8	4,5	896
Juin	4,8	15,7	0	1,5	4	621
Mai	4,8	15,3	0	1,5	4	426,5
Avril	5,2	17,8	0	1,5	4	528,7


L'analyse du profil client révèle une forte hétérogénéité des capacités de financement, avec un encours de crédit moyen de 167,5 kNT\$ marqué par une dispersion considérable (écart-type de 129,7 kNT\$). La structure démographique est majoritairement jeune, 75% de l'échantillon ayant moins de 41 ans pour une

moyenne de 35,5 ans.

Concernant la dynamique des paiements, la stabilité prévaut : les médianes nulles du statut de remboursement indiquent une régularité globale, bien que des retards critiques atteignant huit mois signalent des risques de défaut localisés. Les flux financiers témoignent d'un endettement contrasté, où certains soldes créditeurs (minima négatifs) côtoient des facturations massives. Parallèlement, si le remboursement mensuel moyen s'établit autour de 5 kNT\$, l'amplitude extrême des versements (jusqu'à 1,6 MNT\$) souligne une asymétrie majeure de la distribution.

Cette prévalence de valeurs aberrantes et la forte variance des variables financières imposent une standardisation rigoureuse des données en amont de la modélisation, afin de garantir la stabilité et la convergence des algorithmes linéaires.

Figure 1: Sélection de graphiques pertinents pour l'analyse des distributions des variables à l'aune du défaut de paiement.



- Les clients en défaut disposent de limites de crédit plus faibles en moyenne. Leur médiane est inférieure à celle des clients non défaillants, ce qui suggère que la banque identifie déjà certains profils à risque avant la survenance du défaut.
- Les densités de paiement révèlent, chez les clients en situation de défaut, une concentration croissante des flux autour de 0 NT\$, traduisant une raréfaction des remboursements. Cette distribution plus resserrée fait du comportement de paiement un discriminant potentiellement fort entre les individus en défaut et les autres, a fortiori à l'approche de l'échéance d'octobre.

- La corrélation positive observée traduit la persistance de la dette (**effet de stock**) : la dette de carte de crédit n'est pas un flux ponctuel, mais un stock durable. D'un point de vue statistique, cette forte corrélation peut engendrer un risque de multicolinéarité, les variables apportant une information largement redondante. Cela peut entraîner une instabilité des coefficients dans une régression logistique. Cette observation motive le recours, en complément du modèle logistique, à des modèles d'arbres tels que le **Random Forest** ou **XGBoost**, mieux adaptés à la gestion de cette redondance que les modèles linéaires classiques.

3 Modélisation

Deux étapes clés ont précédé l'implémentation des modèles : (i) la division du jeu de données en un ensemble d'entraînement (80%) et un ensemble de test (20%) ; (ii) le prétraitement des variables, comprenant l'encodage des variables catégorielles par création de variables binaires (one-hot encoding) et la standardisation des variables numériques, centrées sur leur moyenne et réduites par leur écart-type. Ces étapes de prétraitement des données sont primordiales, notamment pour éviter le surapprentissage grâce à la séparation des ensembles d'entraînement et de test, et pour limiter les biais liés aux différences d'échelle par l'harmonisation des variables.

L'évaluation des performances des différents modèles a été réalisée en donnant la priorité au **rappel** pour la classe défaut, afin de mieux détecter les clients présentant un risque de défaut de paiement. En effet, le déséquilibre marqué entre les classes, les défauts étant beaucoup moins nombreux que les non-défauts, rend l'accuracy peu informative, car un modèle peut sembler performant simplement en classant correctement les non-défauts majoritaires.

Le **rappel** mesure la proportion de défauts correctement identifiés parmi tous les défauts réels, tandis que la **précision** indique la proportion de défauts correctement identifiés parmi les prédictions de défaut. En choisissant le rappel comme métrique principale, nous privilégions la capacité du modèle à détecter les défauts, même au détriment de la précision sur les non-défauts.

Le rappel est défini par :

$$\text{Rappel} = \frac{VP}{VP + FN}$$

et la précision par :

$$\text{Précision} = \frac{VP}{VP + FP}$$

où VP (vrais positifs) correspond au nombre de défauts correctement détectés, FP (faux positifs) aux non-défauts incorrectement classés comme défauts, et FN (faux négatifs) aux défauts non détectés par le modèle.

Après le prétraitement des données et la définition de la métrique d'évaluation, nous avons implémenté quatre modèles de classification : une régression logistique (méthode interprétable), deux méthodes ensemblistes (XGBoost et Forêt Aléatoire) et un réseau de neurones. La Table 3 résume les métriques obtenues pour chaque modèle, tandis que la Figure 2 présente les matrices de confusion afin de comparer leurs performances et d'identifier le modèle le plus performant.

Table 3: Comparaison des modèles de prédiction triée par rappel (classe défaut)

Modèle	Accuracy	Rappel (Classe en Défaut)	Précision (Classe en Défaut)
Forêt Aléatoire	0.813	0.365	0.632
XGBoost	0.817	0.359	0.660
Réseau de Neurones	0.794	0.344	0.555
Régression Logistique	0.809	0.244	0.692




Figure 2: Matrice de confusion des modèles comparés

Dans l'ensemble, les modèles affichent une accuracy proche de 80%, portée principalement par la bonne classification des clients non en défaut. La détection des défauts reste plus difficile : près de 70% des défauts sont mal classés en moyenne. La Forêt Aléatoire obtient le meilleur rappel ($\approx 36\%$) pour cette classe, tandis que la régression logistique est la moins performante. Compte tenu de son meilleur rappel et de ses performances globales, nous avons retenu la Forêt Aléatoire pour poursuivre le projet et tenter d'optimiser davantage la détection des défauts.


4 Ajustements et Analyses Approfondies pour le modèle le plus performant : Forêt Aléatoire

Pour optimiser notre modèle de **Forêt Aléatoire**, nous procédons à une **grid search**, c'est-à-dire que nous testons de manière systématique différentes combinaisons de paramètres afin de maximiser le **rappel** pour la détection des défauts de paiement.

La grille de paramètres inclut le nombre d'arbres (**n_estimators**), la profondeur maximale des arbres (**max_depth**) et le nombre minimum d'échantillons nécessaires pour diviser un nœud (**min_samples_split**). Le choix de cette grille réduite résulte de la nécessité de limiter le nombre total de modèles à tester afin de réduire les temps de calcul. Par ailleurs, souvent les paramètres par défaut du modèle sont déjà proches de l'optimal et l'hyperparamétrisation n'a que peu d'impact sur la métrique cible. Ainsi, notre grid search est volontairement restreinte pour tester si des ajustements à la marge de certains paramètres améliorent notre **rappel**. Si cette amélioration s'avère significative, nous pourrions alors explorer une grille de paramètres plus complète.

Par ailleurs, pour chaque combinaison de paramètres, nous utilisons une **validation croisée à 3 plis** afin d'évaluer la robustesse du modèle et d'éviter le surapprentissage. Concrètement, la base de données est divisée en trois sous-ensembles et, pour chaque combinaison de paramètres, le modèle est entraîné sur deux plis et testé sur le troisième. Ce processus est répété trois fois, en faisant tourner le pli de test, ce qui permet de calculer un score moyen et d'obtenir une estimation fiable de la performance du modèle sur des données non vues.

La Grid Search confirme les résultats attendus : les paramètres par défaut du modèle de forêt aléatoire sont ceux qui offrent les meilleures performances. Nous pouvons désormais nous concentrer sur l'analyse des variables les plus déterminantes dans la prédiction du défaut de paiement afin d'interpréter le comportement du modèle.



Le statut de paiement le plus récent (septembre) apparaît comme le principal facteur explicatif du risque de défaut : plus un individu accuse de retards ce mois-ci, plus sa probabilité de défaut en octobre est élevée.

Les autres variables financières, telles que le plafond de crédit, les relevés mensuels et les montants remboursés récents, jouent également un rôle important, reflétant la prise en compte globale de la situation financière du client. En revanche, à l'exception de l'âge, les variables socio-démographiques (niveau d'études, sexe, situation matrimoniale) se situent en fin de classement et contribuent marginalement à la prédiction.

Le modèle repose donc principalement sur la discipline financière et l'historique de paiement, plutôt que sur les caractéristiques sociales.

5 Conclusion

Le projet visait à construire un outil de prédiction du risque de défaut pour une institution financière à Taïwan. À partir de données brutes, nous avons développé un modèle robuste d'aide à la décision. La régression logistique, simple et interprétable, s'est révélée limitée pour détecter les profils à risque (**Recall 0,24**), laissant passer trois défauts sur quatre.

L'utilisation de XGBoost et d'un réseau de neurones a permis de capturer des relations non-linéaires et d'améliorer la détection des défauts. Le modèle de forêt aléatoire s'est imposé comme le plus performant, avec une accuracy de 81,3% et un rappel de 36,5% sur les clients en défaut.

L'analyse des variables montre que les comportements de paiement récents, le montant mensuel facturé et le plafond de crédit sont les facteurs prédictifs dominants, tandis que les variables démographiques, sauf l'âge, ont un poids marginal.

Ces performances doivent être relativisées en raison du fort déséquilibre entre classes : le modèle prédit très bien les clients non défaillants mais peine à identifier les défauts. Pour la banque, l'enjeu reste d'identifier précisément les profils à risque, plutôt que de bien classer les clients à faible risque.